SBNZ – Prijedlog projekta

Sistem za upravljanje vozilima hitne pomoći i procjenu hitnosti slučajeva

Članovi tima:

Branka Kovačević SV72/2022

1. Opis problema

1.1. Motivacija

Efikasno reagovanje hitne pomoći jeste jedan od ključnih faktora za spasavanje ljudskih života. U situacijama kad postoji velik broj poziva (različitih razloga) i ograničen broj vozila, uz dodatne otežavajuće spoljne faktore poput vremenskih prilika, razdaljine i sl, radnici hitne pomoći su primorani da donose brze odluke na osnovu ograničenih informacija. U takvim uslovima može doći do pogrešne procjene hitnosti slučaja, neoptimalnog raspoređivanja vozila što dalje dovodi do kašnjenja u reakciji ili neadekvatne reakcije. Tu se javlja potreba za inteligentnim sistemom koji može analizirati podatke, prepoznati kritične situacije i predložiti optimalne odluke o rasporedu, ruti i odabiru vozila u realnom vremenu.

1.2. Pregled problema

Problem koji se rješava jeste automatizacija procesa:

- procjene hitnosti slučaja
- dodjele odgovarajućeg vozila
- reagovanje na promjene stanja u realnom vremenu

Postojeća rješenja u praksi se zasnivaju na iskustvu operatera i ne koriste rezonovanje nad kombinacijom faktora, ne detektuju promjene kroz vrijeme i nemaju transparentno objašnjenje donijetih odluka.

Nedostaci su nedovoljna adaptivnost načina odlučivanja i nedostatak integrisanog sistema za donošenje odluka.

Predloženo rješenje podrazumijeva rule-based sistem zasnovan na znanju, kombinovanje više izvora podataka, korišćenje CEP za analizu događaja kroz vrijeme, kao i mogućnost objašnjivog rezonovanja.

Prednosti ovog pristupa su transparentnost odluka, fleksibilnost i proširivost, rad u realnom vremenu.

1.3. Metodologija rada

Ulazi u sistem:

- podaci o pacijentu (simptomi, puls, krvni pritisak, starost, stanje svijesti, tjelesna temperatura)
- podaci o pozivu (lokacija, vrijeme poziva, broj pacijenata)
- podaci o vozilima (lokacija vozila, status, oprema)

Lokacija vozila i pacijenta koristi se za procjenu vremena dolaska koje predstavlja pojednostavljenu aproksimaciju rute. Sistem bira vozilo sa minimalnim vremenom dolaska uzimajući u obzir dostupnost i opremljenost.

- spoljni faktori (stanje saobraćaja, vremenski uslovi)

Vrijeme dolaska može biti dinamički prilagođeno na osnovu spoljašnjih faktora poput saobraćaja i vremenskih uslova.

Izlaz iz sistema:

- nivo hitnosti (nizak, srednji, visok, kritičan)
- preporuke (koje vozilo poslati, potreba za dodatnim timom)
- upozorenja (na stanje pacijenata, vremenske prilike, saobraćajne prilike, dostupnost resursa)

1.4. Baza znanja

Baza znanja se sastoji iz više komponenti:

- Pravila (forward chaining):

Pravila se koriste za izvođenje zaključaka kroz više nivoa. Na primjer:

IF bol u grudima AND visok puls → sumnja na ozbiljno stanje

IF ozbiljno stanje AND gubitak svijesti → kritično stanje

IF kritično stanje → maksimalan prioritet

Ova pravila se ulančavaju kroz više nivoa, čime se omogućava kompleksno zaključivanje od osnovnih simptoma do konačne odluke.

- Accumulate funkcije

Koriste se za agregaciju podataka: broj aktivnih poziva, prosječno vrijeme čekanja, opterećenje vozila.

- CEP

Analiza događaja kroz vrijeme, što podrazumijeva pogoršanje stanja pacijenta u vremenskom intervalu, više poziva iz iste oblasti u kratkom vremenu, produženo vrijeme čekanja. Na primjer: IF više od 3 poziva iz iste oblasti u 5 minuta →detekcija incidenta i povećanje prioriteta ili IF stanje pacijenta pokazuje kontinuirano pogoršanje u vremenu → povećanje nivoa hitnosti

- Backward chaining

Koristi se za dijagnostiku i objašnjenje odluka, na primjer zašto je slučaj označen kao kritičan. Tu sistem provjerava simptome, kombinacije simptoma, stanje svijesti.

- Template

Koristi se za definisanje pravila kroz parametre kao što su pragovi za puls, pragovi za pritisak i sl. Ovo omogućava lako prilagođavanje sistema bez izmjene koda.

1.5. Primjer rezonovanja

Ulazni podaci: bol u grudima, visok puls, pacijent u nesvijesti.

Aktivacija pravila: detektuje se kritično stanje.

CEP analiza: stanje se pogoršava kroz vrijeme.

Accumulate: velika opterećenost sistema u toj oblasti.

Zaključak: slučaj se klasifikuje kao kritičan, dodjeljuje se najbliže dostupno vozilo i sa najboljom opremom. Ukoliko najbliže vozilo nije dostupno, sistem bira vozilo sa minimalnim vremenom dolaska koje je slobodno. U slučaju povećanog saobraćaja ili loših vremenskih uslova, procijenjeno vrijeme dolaska se ažurira i može dovesti do promjene vozila.

Backward chaining: sistem može objasniti odluku da je stanje označeno kao kritično zbog kombinacije simptoma i gubitka svijesti.

Sistem omogućava donošenje odluka zasnovanih na kombinaciji više faktora i njihovoj međusobnoj zavisnosti.